Memoria del Proyecto final del Bootcamp de Data Science y Machine Learning

1. Datos generales del proyecto

Componentes

Sergio Salgado Briegas

Título del proyecto

Predicting Transcription Levels of Bacterial Promoters Using Deep Learning

Resumen

Los sistemas biológicos están altamente regulados para alcanzar unas concentraciones adecuadas de cada uno de sus componentes. Uno de sus sistemas de regulación es el control de la expresión génica. La expresión génica controla tanto en el paso de DNA a RNA, en el proceso conocido como transcripción, como de RNA a proteína, en el proceso conocido como traducción. En la primera capa de regulación de la transcripción se encuentran los promotores de los genes, regiones que son reconocidas por la enzima encarga de llevar a cabo la transcripción, la RNA polimerasa. La cantidad de RNA que se produce se regula tanto por la secuencia de los promotores como por la existencia de reguladores de la transcripción, conocidos como represores o activadores. Este proyecto trata de predecir, mediante algoritmos de Deep Learning, la cantidad de RNA producido *in vivo* utilizando datos de secuencias de promotores.

Fundamentos teóricos del proyecto

El material genético de las células almacena la información necesaria para producir las proteínas que sostienen la vida. Esta información se almacena en el DNA en "paquetes" de información conocidos como genes, que se transcriben a RNA en un proceso conocido como transcripción. El RNA a su vez sirve de molde para la síntesis de proteínas durante el proceso llamado traducción. Estos dos procesos están altamente regulados para asegurar que las proteínas se encuentran en una concentración óptima.

La primera capa de regulación de la expresión génica, proceso por el cual un gen da lugar a una proteína, se encuentra en la transcripción. Ésta, es llevada a cabo por la RNA polimerasa, una proteína que se lee el DNA y lo transcribe al RNA. Para que este proceso tenga lugar es necesario que la RNA polimerasa se una a otra proteína conocida como factor sigma (σ), que será la encargada de llevar a cabo la unión con el DNA. El factor σ es el encargado de reconocer al promotor del gen, una secuencia que precede al gen y desde la cual se inicia la transcripción. El factor σ reconoce específicamente las secuencias conocidas como cajas -35 y -10, que se encuentran ampliamente conservadas. La cantidad de RNA que se produzca de ese gen dependerá, en primer lugar, de lo cercana que sea la secuencia del promotor a la secuencia consenso representada en la Figura 1. Por tanto, la concentración basal de RNA de cada gen dependerá de la fuerza del promotor de ese gen y ésta, a su vez, dependerá de la conservación de secuencia.

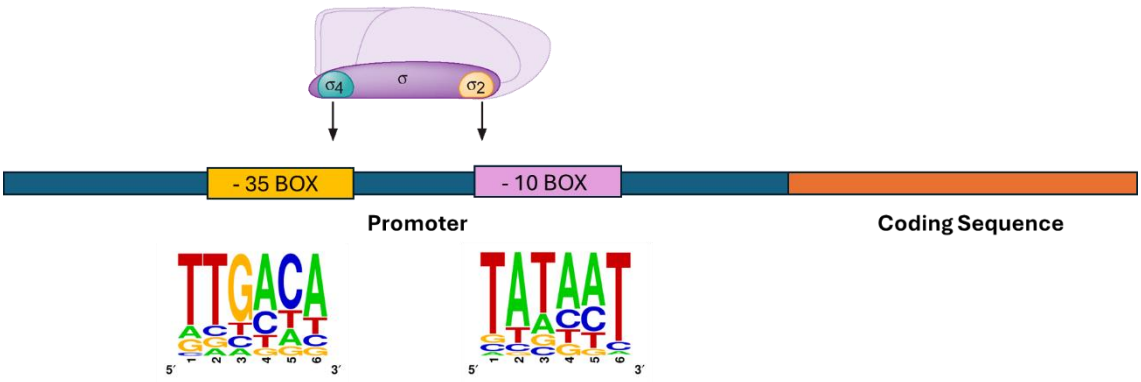

Figura 1. Diagrama de unión de la RNA polimerasa al promotor. La RNA polimerasa unida al factor σ, reconoce las secuencias de las cajas -35 y -10 del promotor, cuyas secuencias consenso se representa bajo cada una de estas cajas.

Además de la fuerza del promotor, la síntesis de RNA va a depender de la acción de proteínas reguladoras, como son los activadores o los represores. Los activadores incrementan la transcripción y se encuentran en una zona precedente a la caja -10. En cambio, los represores inhiben la transcripción y no tienen un sitio específico. Ambos reguladores se unen a secuencias conservadas de entre 15-25 nucleótidos y son específicas para cada regulador.

2. Beneficiarios del proyecto. Valor, utilidad, ¿qué problemas resuelve, a quién va dirigido y por qué crearlo?

Este proyecto va a dirigido principalmente a la comunidad científica, ya que el principal objetivo es incrementar el conocimiento de sistemas biológicos. Para ello trata de dar solución a un problema multifactorial mediante la búsqueda de patrones. Este proyecto surge de la necesidad de poder controlar la expresión génica mediante una amplia batería de promotores, con el fin de poder generarse combinaciones que permitan un fino ajuste en la modificación de sistemas biológicos para dotarlos de nuevas capacidades.

3. Ejecución del proyecto. Proceso de desarrollo, dificultades, metodologías y tecnologías empleadas.

<u>Construcción del dataset</u>

En primer lugar, se buscaron las secuencias de promotores de la bacteria modelo *Escherichia coli*. Para ello, se utilizó la base de datos RegulonDB [1]. Se descargó la base de datos no relacional y mediante el software MondoDB Compass se extrajo la información relativa a los promotores en formato JSON. El archivo obtenido fue procesado empleando Python los módulos pandas y json para obtener el nombre de cada promotor, la secuencia y el gen (o unidad de transcripción) bajo su control. Por otro lado, de la base de datos iModulonDB [2] se obtuvieron los datos relativos a la transcripción de 4257 genes en 166 condiciones experimentales, necesarios para construir la 'y' con la que entrenar al modelo.

<u>Preprocesamiento del dataset</u>

El reconocimiento de la secuencia de los promotores por parte de la RNA polimerasa se lleva a cabo mediante la interacción otra proteína auxiliar conocida como factor sigma (σ). Es el factor σ quien reconoce la secuencia del promotor en el DNA. Debido a la existencia de múltiples factores σ, se redujo la complejidad seleccionando solo aquellos promotores reconocidos por el factor σ_{70}. Además, se filtraron aquellos genes controlados por diferentes promotores, con el fin

de reducir contradicciones en los datos. Para obtener los datos de salida del modelo, se buscaron los genes coincidentes entre la tabla de promotores y la tabla de datos de transcripción. La principal dificultad de este proyecto se encuentra en los valores de salida de cada gen, ya que estos dependen de la regulación de cada gen y estas a su vez depende de las condiciones experimentales. Se producen por lo tanto diferentes distribuciones en los datos de esta tabla (Figura 2). Para poder simplificar el proceso de selección de los valores de salida, se eligió la moda de la transcripción de cada gen. Con estos valores, los promotores se clasificaron en fuerza 'Low', 'Medium' y 'Strong'.

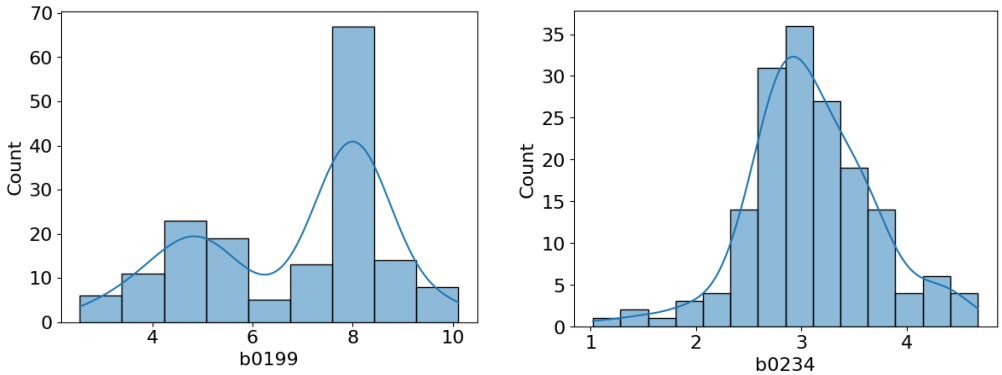

Figura 2. Histogramas de la concentración de RNA de dos genes

<u>Construcción de algoritmos</u>

A pesar de la existencia de patrones en las secuencias de promotores (tanto para el reconocimiento de los factores σ como para la unión de reguladores) estas secuencias pueden estar ligeramente desplazas (Figura 3), imposibilitando el establecimiento de correlaciones entre un determinado nucleótido en una determinada posición y la transcripción de un gen.

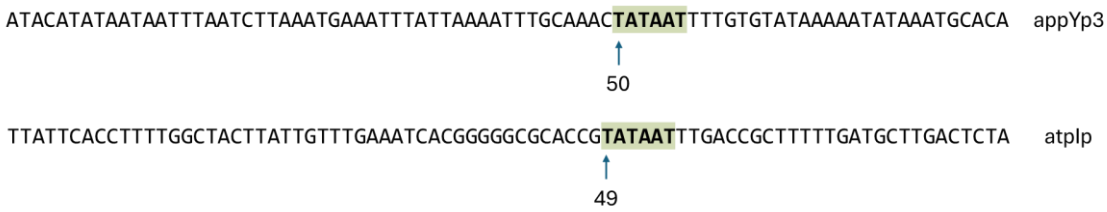

Figura 3. Secuencias de dos promotores. En el recuadro verde aparece representada la caja -10 de estos dos promotores.

Para poder reconocer estos patrones conservados en diferentes posiciones se ha empleado un algoritmo de Deep Learning empleando Redes Convolucionales de una dimensión (1D CNN). Estas redes recorren el input en ventanas del tamaño deseado y lo transforman en una señal para las siguientes capas. Las secuencias promotoras tienen que ser codificadas para que una red convolucional pueda recorrerla. Por tanto, en primer lugar, se lleva a cabo la transformación de las secuencias en vectores binarios que servirán de entrada al modelo. Debido al diferente tamaño de los patrones a encontrar (6 nucleótidos para las cajas que forman el promotor y 18 nucleótidos para los reguladores), en este proyecto se ha empleado una red convolucional de tipo inception, que combina convoluciones de diferentes tamaños de kernel. En estas convoluciones se ha empleado un padding 'same' que mantiene el tamaño de las ventanas y un MaxPooling de pool size 2 y de stride 2, reduciéndose la complejidad de los cálculos. Tras la concatenación de los filtros de convolución y el flattening, la capa resultante se ha utilizado como input para una red neuronal totalmente interconectada y una última capa de salida con tres

neuronas que permita clasificar los promotores como ‘Low’, ‘Medium’ o ‘Strong’. El algoritmo completo se resume en la Figura 4.

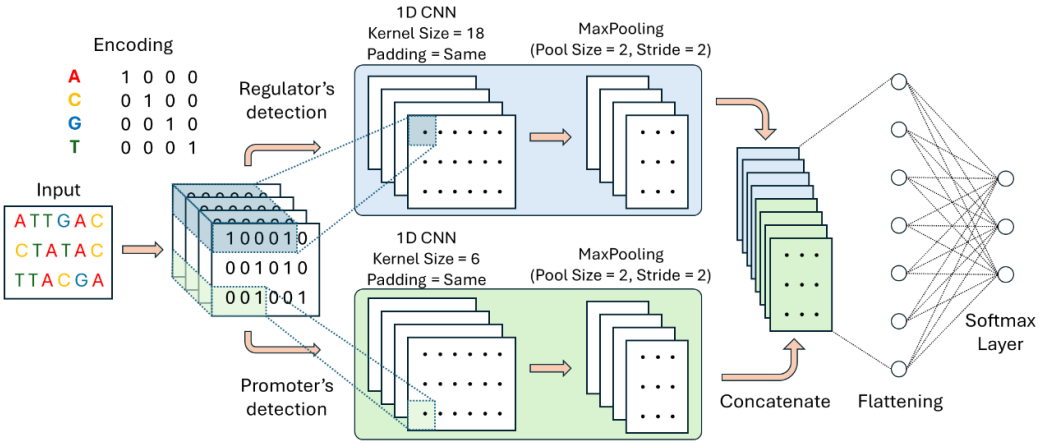

Figure 4. Diagrama del algoritmo aplicado en el proyecto. En el aparece representado el preprocesamiento de secuencias para codificarlas en vectores de 0 y 1. Tras este procesamiento aparece una red convolucional tipo inception de dos torres de convolución que se concatenan y se aplanan para servir de input a una red neuronal multicapa que clasifica las secuencias de los promotores.

4. Impacto y resultado. ¿Cuál ha sido el resultado final?

El algoritmo de Deep Learning construido en este proyecto permite la clasificar la fuerza de los promotores de *E. coli* en ‘Low’, ‘Medium’ y ‘Strong’ empleando únicamente su secuencia, a partir de datos de transcripción disponibles en la literatura. A pesar del bajo volumen de datos con los que se ha entrenado el modelo (únicamente con 660 secuencias de promotores y sus respectivos niveles de transcripción), el modelo es capaz de clasificar los promotores con un R^2 score cercano al 0.6, comparable a los resultados obtenidos en trabajos similares en los que hacen una clasificación binaria de los promotores en ‘Low’ y ‘Strong’ [3].

La sobrerrepresentación de secuencias de promotores medios (Figura 5A), ocasiona que el modelo clasifique peor las otras clases, ya que no tiene suficientes patrones de aprendizaje (Figura 5B)

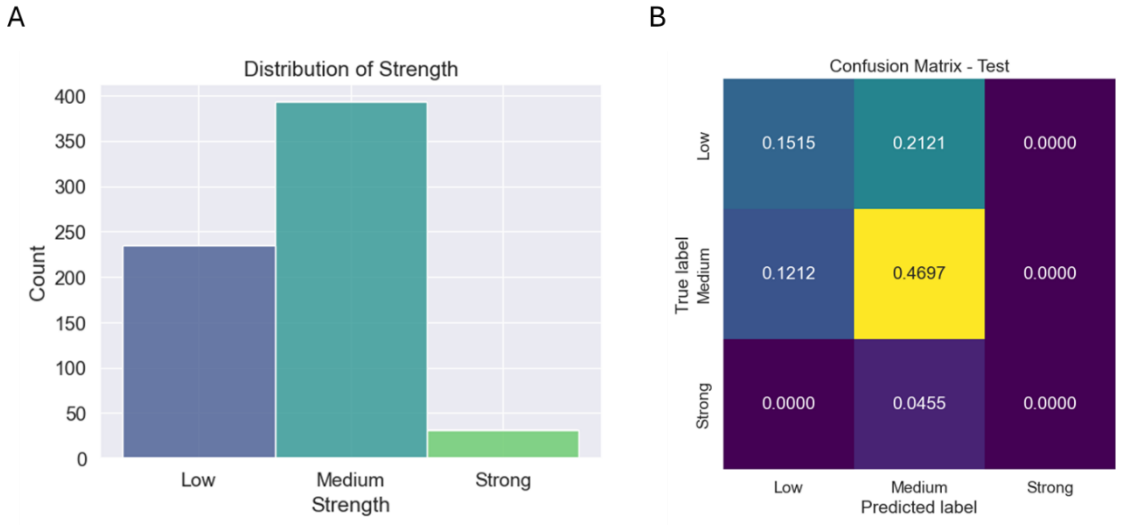

Figura 5. A) Distribución de los promotores en las clases ‘Low’, ‘Medium’ y ‘Strong’. B) Matriz de confusión obtenida durante la validación del algoritmo de Deep Learning.

5. Líneas de continuidad. Si el proyecto continuase, ¿cuál sería el foco a futuro?

El proyecto podría continuar mediante la división en diferentes subproyectos. En primer lugar, podría continuar para incrementar la precisión en el reconocimiento de secuencias de unión de los reguladores, para ver qué regulación afecta a cada gen. Posteriormente, habría que estudiar cómo afectan las variaciones en la secuencia al efecto que tienen los reguladores en cada gen bajo su regulación. Una vez obtenidos estos datos, habría que buscar como poder introducir la información de los reguladores dentro de las variables de la X, ya que el principal problema de este proyecto es que los datos de salida dependen a su vez de los propios datos de salida (la transcripción de los genes depende de la concentración de los reguladores, que a su vez forman parte de la Y).

6. Conclusiones

Las conclusiones obtenidas en este proyecto son las siguientes:

- Las redes neuronales convolucionales permiten la identificación de patrones que facilitan la clasificación de promotores utilizando datos de transcripción.
- Las clases desequilibradas conducen a la identificación incorrecta de las clases subrepresentadas.
- Localizar el problema en un solo gen y aumentar la cantidad de datos permite la identificación de los nucleótidos que contribuyen a la fuerza del promotor.

7. Anexos. Incluyendo bibliografía de interés, cualquier documento adicional o fotos y vídeos del proyecto.

[1] H. Salgado *et al.*, «RegulonDB v12.0: a comprehensive resource of transcriptional regulation in E. coli K-12», *Nucleic Acids Res*, vol. 52, n.º D1, pp. D255-D264, nov. 2023, doi: 10.1093/nar/gkad1072.

[2] K. Rychel, K. Decker, A. V. Sastry, P. V. Phaneuf, S. Poudel, y B. O. Palsson, «iModulonDB: a knowledgebase of microbial transcriptional regulation derived from machine learning», *Nucleic Acids Research*, vol. 49, n.º D1, pp. D112-D120, ene. 2021, doi: 10.1093/nar/gkaa810.

[3] H. Tayara, M. Tahir, y K. T. Chong, «Identification of prokaryotic promoters and their strength by integrating heterogeneous features», *Genomics*, vol. 112, n.º 2, pp. 1396-1403, mar. 2020, doi: 10.1016/j.ygeno.2019.08.009.